

1 バイズ回帰 (ボードゲーム班)

1.1 はじめに

(この記事の執筆時点で、企画の詳細が定まっていないため、ボードゲーム班の企画とどの程度関連があるのかは分かりませんが、ご了承ください。)

バイズの考え方はニューラルネットワークなどの機械学習の分野でもよく用いられており、ベイジアンニューラルネットワーク (BNN) などが知られています。ここでは BNN 自体は扱いませんが、直感的に理解しやすい回帰という問題設定において、バイズの考え方と、それとよく対比される頻度論的 (frequentist) な考え方を比較して、バイズの有用性を探ります。

他の記事は難しそうなのですが、この記事は高校生でも理解できる説明を目指します (というつもりで書いたのですが、行列を回避できませんでした...).

1.2 回帰

まず、回帰について説明します。ここで扱う回帰とは、二つのデータの組 (x_i, y_i) が与えられたときに、それらの関係を推定する問題です (なお、一般的には「回帰」はもっと広い問題設定ですが、ここではその特別な場合を扱います)。さっそく例を見てみましょう。


例

ある現象を観測して、次のようなデータが得られたとします。

表 1: データ

x	y
1.47	0.99
0.47	0.53
-1.78	-0.82
1.53	0.69
-0.41	-0.36

図 1: データのプロット



ここで、この現象は $y = w_0 + w_1x + w_2x^2 + w_3x^3$ というモデルでそれなりによく近似できると仮定します。どのようにして x と y の関係性を推定すれば良いでしょうか？

ここでいう「関係性」とは、パラメータ w_0, w_1, w_2, w_3 のことだと思っていただいて構いません。実際、もしこれらを知ることができたら、この現象は十分解明できたと言えるでしょう。

1.3 頻度論的な考え方

頻度論という言葉は馴染みがないかもしれませんが、高校や大学でやるような、最小二乗法で最も近似できる曲線を求めることを考えます。先ほどの問題に最小二乗法を適用してみましょう。

$x = x_i$ に対して、モデルの予測値は $\hat{y}_i = w_0 + w_1x_i + w_2x_i^2 + w_3x_i^3$ となります。この予測値と実際のデータ y_i の誤差は $y_i - \hat{y}_i$ となります。この誤差の二乗の平均を最小化するような w_0, w_1, w_2, w_3 を求めることが目標です。

式で書くと、

$$E(w_0, w_1, w_2, w_3) := \frac{1}{5} \sum_{i=1}^5 (y_i - \hat{y}_i)^2 = \frac{1}{5} \sum_{i=1}^5 (y_i - (w_0 + w_1x_i + w_2x_i^2 + w_3x_i^3))^2$$

と定義した誤差関数 E について、 E を最小化するような w_0, w_1, w_2, w_3 を求めれば良いです。これらは、各 w_i について偏微分するなどして求めることができます。コンピュータによる計算の結果は以下のようになります。

$w_0 = 0.0790, w_1 = 1.09, w_2 = -0.0618, w_3 = -0.218$

これをプロットすると次のようになります。




図 2: 頻度論的な考え方による近似

見ての通り、直感的にはよく近似できているように見えます。ただし、一つ問題があります。たった 5 つのデータで推定した結果がどのくらい信用できるのでしょうか？ もしたまたま、本

来なら外れ値であるはずのデータがここに入っていたらどうでしょうか？ まだこの現象をきちんと理解したと言いつけるには早い気がします。

1.4 ベイズ的な考え方

前置きが長くなりましたが、ベイズ的な考え方をを用いてこの問題を解いてみましょう。頻度論的な考え方の欠点は、データが少ないにも関わらず関係性 (w_i というパラメータ) を一つだけ推定してしまい、その結果がどれだけ信頼できるかわからないことでした。これに対して、ベイズ線形回帰は各パラメータを確率分布として推定することでこの問題に対処します。具体的には以下の流れで行います。

1. パラメータ w_0, w_1, w_2, w_3 の事前分布と、データ y_i の分布を仮定する。
2. ベイズの定理を用いて、与えられたデータからパラメータ w_0, w_1, w_2, w_3 の事後分布を計算する。
3. 事後分布から、予測分布を計算する。

1.4.1 事前分布の仮定

まず、パラメータ w_0, w_1, w_2, w_3 の事前分布を与えます。ここでは、はじめ各 w_i が独立に平均 0、分散 σ_w^2 のガウス分布 (正規分布) に従っていると仮定します。一方、データ y_i は平均 $w_0 + w_1x_i + w_2x_i^2 + w_3x_i^3$ 、分散 σ_y^2 のガウス分布に従っていると仮定します。すなわち、

$$p(w_0, w_1, w_2, w_3) = \prod_{i=0}^3 \mathcal{N}(w_i | 0, \sigma_w^2) \quad (1)$$

$$p(y_i | x_i, w_0, w_1, w_2, w_3) = \mathcal{N}(y_i | w_0 + w_1x_i + w_2x_i^2 + w_3x_i^3, \sigma_y^2) \quad (2)$$

ここで、 $\mathcal{N}(x | \mu, \sigma^2)$ は平均 μ 、分散 σ^2 のガウス分布の確率密度関数を表します。具体的には、

$$\mathcal{N}(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

です。

なお、ここでの二つの分散は勝手に仮定したもので、人間が適当に決めます。

この段階ではまだデータを使っておらず、パラメータの分布は不正確です。ここからデータを用いてパラメータの分布をもっともらしいものに近づけていきます。そうすることで、より確からしい関係性を推定することができます。

1.4.2 事後分布の計算

次に、与えられたデータとベイズの定理から、 w_i の事後分布を計算します。以下、表記の簡略化のために、 w_0, w_1, w_2, w_3 をまとめて $\mathbf{w}$ と書き、データ (x_i, y_i) をまとめて $\mathcal{D}$ と書きます。ベイズの定理より、

$$p(\mathbf{w}|\mathcal{D}) = \frac{p(\mathcal{D}|\mathbf{w})p(\mathbf{w})}{p(\mathcal{D})} \quad (3)$$

これを計算していきます。ここで、(1) と (2) より、

$$p(\mathcal{D}|\mathbf{w}) = \prod_{i=1}^5 \mathcal{N}(y_i | w_0 + w_1 x_i + w_2 x_i^2 + w_3 x_i^3, \sigma_y^2) \quad (4)$$

$$p(\mathbf{w}) = \prod_{i=0}^3 \mathcal{N}(w_i | 0, \sigma_w^2) \quad (5)$$

となります。ここで、

$$\mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ y_4 \\ y_5 \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ w_2 \\ w_3 \end{pmatrix}, \quad \phi(x_i) = \begin{pmatrix} 1 \\ x_i \\ x_i^2 \\ x_i^3 \end{pmatrix}$$

とし、さらに $\phi(x_i)$ を縦に並べた行列

$$\Phi = \begin{pmatrix} \phi(x_1)^\top \\ \phi(x_2)^\top \\ \phi(x_3)^\top \\ \phi(x_4)^\top \\ \phi(x_5)^\top \end{pmatrix}$$

を導入します。すると、モデルの予測値 $w_0 + w_1 x_i + w_2 x_i^2 + w_3 x_i^3$ は $\phi(x_i)^\top \mathbf{w}$ と書けます。この表記を使うと (以下、途中で出てくる $\mathbf{w}$ に関係ない定数は重要でないので const と書きます)、

$$p(\mathbf{w}|\mathcal{D}) = \text{const} \times \exp \left(-\frac{1}{2\sigma_y^2} \|\mathbf{y} - \Phi \mathbf{w}\|^2 - \frac{1}{2\sigma_w^2} \mathbf{w}^\top \mathbf{w} \right) \quad (6)$$

$$= \text{const} \times \exp \left(-\frac{1}{2} \mathbf{w}^\top \left(\frac{1}{\sigma_y^2} \Phi^\top \Phi + \frac{1}{\sigma_w^2} I \right) \mathbf{w} + \frac{1}{\sigma_y^2} \mathbf{y}^\top \Phi \mathbf{w} \right) \quad (7)$$

この式の指数部分を平方完成すると、(7) 式は 4 変数のガウス分布になって、

$$p(\mathbf{w}|\mathcal{D}) = \mathcal{N}(\mathbf{w} | \boldsymbol{\mu}_w, \Sigma_w) \quad (8)$$

と書けます。ここで、

$$\Sigma_w^{-1} = \frac{1}{\sigma_y^2} \Phi^\top \Phi + \frac{1}{\sigma_w^2} I \quad (9)$$

$$\boldsymbol{\mu}_w = \frac{1}{\sigma_y^2} \Sigma_w \Phi^\top \mathbf{y} \quad (10)$$

としました。

このセクションの結果をまとめると、データ $\mathcal{D}$ によって、パラメータ $\mathbf{w}$ の分布を更新することができて、具体的には $\mathbf{w}$ 全体が (9) と (10) から定まるガウス分布 $\mathcal{N}(\boldsymbol{\mu}_w, \Sigma_w)$ に従うと考えることができます。これは先ほどの頻度論的な考え方 (最小二乗法) とは明らかに違いますね。最小二乗法では $\mathbf{w}$ の値は一つに決まりましたが、ここではどの値をとるか定まっておらず確率的です。

1.4.3 予測分布の計算

最後に、更新したパラメータ (の分布) を使って、 x_i と y_i の関係性を推定することを考えましょう。もともとこれが目的でした。そのために、新しく x_k が与えられたときに、それに対応する y_k がどうなるかを考えます。素直に以下の式で計算すると少し大変です。

$$p(y_k | x_k, \mathcal{D}) = \int p(y_k | x_k, \mathbf{w}) p(\mathbf{w} | \mathcal{D}) d\mathbf{w} \quad (11)$$

これを計算せず、ガウス分布の再生性という性質を用いると、(2) と (7) より (詳細は省きますが)、

$$p(y_k | x_k, \mathcal{D}) = \mathcal{N}(y_k | \boldsymbol{\phi}(x_k)^\top \boldsymbol{\mu}_w, \boldsymbol{\phi}(x_k)^\top \Sigma_w \boldsymbol{\phi}(x_k) + \sigma_y^2) \quad (12)$$

となります。これも最小二乗法の結果と違うことがわかります。最小二乗法では、 $y_k = \sum_{i=0}^3 w_i x_k^i$ と決定的に値が決まりますが、ここではやはり確率的に y_k の値を推定しています。

1.4.4 結果の可視化

最後に、ここで得られたベイズ線形回帰の結果を可視化します。ここでは $\sigma_y^2 = 0.04$, $\sigma_w^2 = 1$ としました。




図 3: ベイズ線形回帰の結果

ここで、濃い赤い線が (12) に示されている予測分布の平均値です。薄い領域は、それに対して標準偏差の 2 倍を足したものと引いたものを表しています。ガウス分布なので、これはおよそ 95% の確率でこの範囲に収まるというある種の確信度を表しているとも見ることができます。データが少ない左端と右端はあまり自信がないことがわかりますね。

さらに、この後新しくデータを観測することができて、合計 100 個のデータを使えるようになったとしましょう。その場合、以下ようになります。




図 4: ベイズ線形回帰の結果 2

データが多くなったことで、薄赤の領域が狭くなってきました。これは、たくさんのデータを得て、信頼度が上がってきたと見るすることができます。

1.5 おわりに

ベイズ線形回帰について説明しました。頻度論的なアプローチに対して、ベイズ的な考え方は不確実性を上手く扱えるという長所がありますが、一方で短所もあります。その一つは、事前分布の仮定です。何も仮定しなくて良い最小二乗法と比べて、今回扱ったベイズ線形回帰は事前分布を仮定しました。この仮定はそれなりに強い仮定で、必ずしも上手くいくとは限りません。この記事を書くにあたって、[1], [2] を参考にしました。また、可視化などのためにここで用いたコードは、<https://github.com/Ratstar216/mayfes2026-bayes-article> で後悔しています。

参考文献

- [1] Grosse, Roger and Farahmand, Amir-massoud and Carrasquilla, Juan. *CSC 411 Lecture 19: Bayesian Linear Regression*. University of Toronto, 2018. https://www.cs.toronto.edu/~rgrosse/courses/csc411_f18/slides/lec19-slides.pdf accessed on 2026-04-26.
- [2] 須山, 敦志. ベイズ深層学習. 講談社, 2019.